인공지능 과제 리포트

과제 제목: iris data 분류/KNN 구현

학번: B511226

이름: 홍현승

1. 과제 개요

150행으로 이루어진 iris data-> 140개의 train data와 10개의 test data로 분할 1개의(1행) irisdata는 4개의 feature을 가지고 있고, label로 3개의 class인 Setosa, Versicolor, Virginca에 해당된다.

train 데이터 140개를 공간상에 찍어두고, 10개의 test data로, 140개의 데이터중 어느 데이터랑 가장 근접한지(KNN, weighted KNN) 판단하여 출력해보는 과제.

2. 구현 환경

OS: Window

Integrated Development Environment: Jupyter

Using library: math / sklearn / numpy

3. 알고리즘에 대한 설명

KNN 알고리즘은 기존 데이터(training data)를 학습 시킨 후, 이 데이터중 test data가 가장 가까운 부류가 무엇인지 선택하는 알고리즘이다. 이때 "가장 가까운 부류를 선택"하는 방식에는 majority vote 방식이 있고, weighted majority vote 방식이 있다. 이때 사용자가 지정하는 k, 즉 몇 개의 근접 data를 잡을 것인지를 판단하게 되는데, k가 너무 적으면 data underfitting이, k가 너무 커지면 data overfitting이 일어나 판단 오류가 생기게 된다.

4. 데이터에 대한 설명

4.1 Input Feature

150*5 iris data -> (140*4 training data, 140*1 training data의 label data) / (10*4 test data, 10*1 test data의 label data)로 train test split구현,

4.2 Target Output

test data로 train data와 근접한 class를 예측 -> 예측 값은 10 * 1행렬 (setosa/versicolor/virginica로 구성)을, 실제 test data의 class와 일치하는지 비교

5. 학습 과정에 대한 설명

1)140개의 training data를 공간에 찍어두고 10개의 test data를 넣음

2)각각의 test data(10개)의 training data와의 거리를 구함

->def distance(p1, p2):

p1 = np.array(p1)

p2 = np.array(p2)

return np.sqrt(np.sum(np.power((p2-p1),2)))

3)"test data 1개"와 "train data 140개"의 거리가 담겨있는 dist 리스트(1*140행렬)를 sorting 한다 ->이러면 가까운 거리부터 앞에 오게 된다

->temp = dist.argsort() =>cf)이때 temp를 찍어보면, 값이 아닌 index가 결과로 나온다!! 4)k(k = 3,5,10)에 따라 temp(인덱스가 담겨있다)에서 앞에 3개/5개/10개를 뽑는다.

5)3개/5개/10개중 voting을 거쳐 가장 많이 존재하는 값을 선택한다.

7. 결과 및 분석

Majority Vote, K = 3

```
for i in range(10):
    print("Test Data Index: "+ str(i), end =' ')
    classify(train_data, test_data[i], 3, train_label)|
    print("True class: "+ flowers[int(test_label[i])])

Test Data Index: 0 computed class: Setosa True class: Setosa
    Test Data Index: 1 computed class: Setosa True class: Setosa
    Test Data Index: 2 computed class: Setosa True class: Setosa
    Test Data Index: 3 computed class: Versicolor True class: Versicolor
    Test Data Index: 4 computed class: Versicolor True class: Versicolor
    Test Data Index: 5 computed class: Versicolor True class: Versicolor
    Test Data Index: 6 computed class: Virginica True class: Virginica
    Test Data Index: 8 computed class: Virginica True class: Virginica
    Test Data Index: 8 computed class: Virginica True class: Virginica
    Test Data Index: 9 computed class: Virginica True class: Virginica
```

Majority Vote, K = 5

```
for i in range(10):
    print("Test Data Index: "+ str(i), end =' ')
    classify(train_data, test_data[i], 5, train_label)
    print("True class: "+ flowers[int(test_label[i])])
```

```
Test Data Index: 0 computed class: Setosa True class: Setosa
Test Data Index: 1 computed class: Setosa True class: Setosa
Test Data Index: 2 computed class: Setosa True class: Setosa
Test Data Index: 3 computed class: Versicolor True class: Versicolor
Test Data Index: 4 computed class: Versicolor True class: Versicolor
Test Data Index: 5 computed class: Versicolor True class: Versicolor
Test Data Index: 6 computed class: Virginica True class: Virginica
Test Data Index: 7 computed class: Virginica True class: Virginica
Test Data Index: 8 computed class: Virginica True class: Virginica
Test Data Index: 9 computed class: Virginica True class: Virginica
```

Majority Vote, K = 10

```
for i in range(10):
    print("Test Data Index: "+ str(i), end =' ')
    classify(train_data, test_data[i], 10, train_label)
    print("True class: "+ flowers[int(test_label[i])])

Test Data Index: 0 computed class: Setosa True class: Setosa
Test Data Index: 1 computed class: Setosa True class: Setosa
Test Data Index: 2 computed class: Setosa True class: Setosa
Test Data Index: 3 computed class: Versicolor True class: Versicolor
Test Data Index: 4 computed class: Versicolor True class: Versicolor
Test Data Index: 5 computed class: Versicolor True class: Versicolor
Test Data Index: 6 computed class: Virginica True class: Virginica
Test Data Index: 7 computed class: Virginica True class: Virginica
Test Data Index: 8 computed class: Virginica True class: Virginica
Test Data Index: 9 computed class: Versicolor True class: Virginica
```

Weighted Majority Vote, K = 3

```
print("Test Data Index: "+ str(i), end = ' ')
weighted_classify(train_data, test_data[i], 3, train_label)
print("True class: "+ flowers[int(test_label[i])])

Test Data Index: 0 computed class: Setosa True class: Setosa
Test Data Index: 1 computed class: Setosa True class: Setosa
Test Data Index: 2 computed class: Setosa True class: Setosa
Test Data Index: 3 computed class: Versicolor True class: Versicolor
Test Data Index: 4 computed class: Versicolor True class: Versicolor
Test Data Index: 5 computed class: Versicolor True class: Versicolor
Test Data Index: 6 computed class: Virginica True class: Virginica
Test Data Index: 7 computed class: Virginica True class: Virginica
Test Data Index: 8 computed class: Virginica True class: Virginica
Test Data Index: 9 computed class: Versicolor True class: Virginica
Test Data Index: 9 computed class: Versicolor True class: Virginica
```

Weighted Majority Vote, K = 5

```
► for i in range(10):
       print("Test Data Index: "+ str(i), end =' ')
       weighted_classify(train_data, test_data[i], 5, train_label)
       print("True class: "+ flowers[int(test_label[i])])
   Test Data Index: O computed class: Setosa True class: Setosa
   Test Data Index: 1 computed class: Setosa True class: Setosa
   Test Data Index: 2 computed class: Setosa True class: Setosa
   Test Data Index: 3 computed class: Versicolor True class: Versicolor
   Test Data Index: 4 computed class: Versicolor True class: Versicolor
   Test Data Index: 5 computed class: Versicolor True class: Versicolor
   Test Data Index: 6 computed class: Virginica True class: Virginica
   Test Data Index: 7 computed class: Virginica True class: Virginica
   Test Data Index: 8 computed class: Virginica True class: Virginica
   Test Data Index: 9 computed class: Versicolor True class: Virginica
Weighted Majority Vote, K = 10
```

```
► for i in range(10):
        print("Test Data Index: "+ str(i), end =' ')
        weighted classify(train data, test data[i], 10, train label)
         print("True class: "+ flowers[int(test_label[i])])
     Test Data Index: O computed class: Setosa True class: Setosa
     Test Data Index: 1 computed class: Setosa True class: Setosa
     Test Data Index: 2 computed class: Setosa True class: Setosa
     Test Data Index: 3 computed class: Versicolor True class: Versicolor
     Test Data Index: 4 computed class: Versicolor True class: Versicolor
     Test Data Index: 5 computed class: Versicolor True class: Versicolor
     Test Data Index: 6 computed class: Virginica True class: Virginica
     Test Data Index: 7 computed class: Versicolor True class: Virginica
     Test Data Index: 8 computed class: Versicolor True class: Virginica
     Test Data Index: 9 computed class: Versicolor True class: Virginica
K = 3,5 인 경우 적중하는 결과를 보였으나, K = 10인 경우 Data overfitting에 의한 이상치
가 생기는 현상을 발견 할 수 있었다.
```

!!!번외!!!!

```
거리 선정을 다른 방식으로 잡은 경우, (pandas를 사용해 보았습니다)
diff = test_data - train_data
diff sq = diff**2
row_sum = diff_sq.sum(axis = 1)
distance = np.sqrt(row_sum)
"Data underfitting"에서 이상치가 생기는 현상을 발견하였습니다.
```

k 가 3일때

k 가 5일때

k 가 7일때

k 가 10일때